

Évaluation de l'impact des campagnes de santé publique sur la population



Pôle Projet P15



MOVEMBER



Introduction

- **Campagnes de santé publique** → des investissements importants (~10 milliards d'euros en France)
- Leur **efficacité** réelle → reste difficile à **mesurer** à grande échelle

→ Comment **mesurer** quantitativement **l'impact** des campagnes de santé publique **sur l'intérêt de la population** ?

Data utilisées

Google Trends (GT)

- **Indice d'intérêt relatif** (0-100) lié aux requêtes Google dans une zone donnée

MediaCloud (MC)


- Volume des **articles médiatiques**
- Collection de **journaux français**

La question

**sensibilisation (MC) → intention (GT) →
dépistage → diagnostic → soins (MedicAM) ?**

Nécessité de construire des requêtes différentes GT/MC

- GT capte le langage de la recherche spontanée
- MC capte le langage éditorial



Optimiser les requêtes séparément est nécessaire
pour maximiser la qualité du signal dans chaque
canal.

Data visualisation



Figure 2 : Visualisation des séries GT & MC, requêtes optimisées

Liens de causalité prédictive entre GT et MC

Test de Granger, modèle linéaire

Construction du jeu de données

- **Movember** — du 1er octobre au 31 décembre (3 mois)
- **Dry January** — du 26 décembre au 6 février (42 jours)
- **Octobre Rose** — du 1er septembre au 30 novembre (3 mois)
- **Mars Bleu** — du 2 février au 30 avril (3 mois)

Construction du jeu de données





Figure 3 : Visualisation des données MC & GT autour du pic pour Octobre Rose et Novembre

Construction du jeu de données



Figure 4 : Visualisation des données MC & GT autour du pic pour Dry January et Mars Bleu

Granger : le modèle VAR (Vector AutoRegressive)

GT → MC

$$\text{Modèle complet : } MC_t = \sum_{k=1}^p \alpha_k MC_{t-k} + \sum_{k=1}^q \beta_k GT_{t-k} + \varepsilon_t$$

$$\text{Modèle réduit (} H_0 \text{) : } MC_t = \sum_{k=1}^p \alpha_k MC_{t-k} + \varepsilon_t, \quad H_0 : \beta_1 = \dots = \beta_q = 0$$

MC → GT

$$GT_t = \sum_{k=1}^p \alpha_k GT_{t-k} + \sum_{k=1}^q \beta_k MC_{t-k} + \varepsilon_t$$

$$GT_t = \sum_{k=1}^p \alpha_k GT_{t-k} + \varepsilon_t, \quad H_0 : \beta_1 = \dots = \beta_q = 0$$

Granger : calcul de la p-value et R^2

Statistique de Fisher

$$F = \frac{(RSS_{\text{red}} - RSS_{\text{full}})/q}{RSS_{\text{full}}/(n - p - q - 1)} \sim F(q, n - p - q - 1)$$

n = nombre d'observations, p = lags de la variable dépendante, q = lags de la variable explicative

$$p\text{-value} = P(F(q, n - p - q - 1) \geq F_{\text{obs}}) \text{ sous } H_0$$

$$R^2_{\text{aj, rduit}} = 1 - (1 - R^2_{\text{rduit}}) \frac{n - 1}{n - p - 1} \quad (k = p)$$

$$R^2_{\text{aj, complet}} = 1 - (1 - R^2_{\text{complet}}) \frac{n - 1}{n - p - q - 1} \quad (k = p + q)$$

$$\Delta R^2_{\text{aj}} = R^2_{\text{aj, complet}} - R^2_{\text{aj, rduit}}$$

Granger : choix des lags (p^* , q^*) par minimisation AIC

Exemple : Octobre Rose




Figure 5 : Heatmap choix des lags par critère AIC pour Octobre Rose (MC→GT et GT→MC)

Résultats Granger linéaire




Figure 6 : Écarts de R^2 pour chacune des campagnes (MC->GT et GT->MC)

- **GT est très autorégressif**
- **Des p-value < 0,005 (cf annexe)**

Résultats Granger - vérification LOYO - p-values

- 2021 contribue, pour Mars bleu, à une causalité plus significative MC->GT





Figure 9 : p-values du test F pour la causalité de Granger linéaire LOYO (GT->MC et MC->GT) en fonction des années


Résultats Granger - vérification LOYO GT->MC



- Octobre Rose et Dry January : les plus robustes

Figure 10 : R² du test F pour la causalité de Granger linéaire LOYO (GT->MC) en fonction des années

Résultats Granger - vérification LOYO MC->GT



- GT est très autorégressif

Figure 11 : R^2 du test F pour la causalité de Granger linéaire LOYO (MC->GT) en fonction des années

Intégration des séries Medic'AM

- **Data : ordonnances des médicaments en pharmacie de ville et à l'hôpital**
- **Chaque médicament : repéré par un code ATC**
(qualifie les principes actifs)

Data Medic'AM vs GT-MC

Données Medic'AM
n'évoluent pas de la même
manière que Google Trends
et MediaCloud





Figure 12 : Séries brutes, normalisées Medic'AM, GT & MC par campagne en fonction des années²⁰

Data Medic'AM-GT-MC - comparaison trends



Figure 14 : Décomposition STL Medic'AM pour Mois sans tabac & Journée de la Santé mentale


Data Medic'AM-GT-MC - comparaison trends



- Dry January accompagne une tendance sociétale de fond
- Octobre Rose, Mars Bleu, Movember : augmentation des taux d'incidence des cancers

Figure 13 : Tendance Medic'AM, GT, MC par campagne en fonction des années


Limites des données Medic'AM



Sources : Données issues des CRCDC et ELP de l'Insee. Traitement Santé publique France, mars 2025

Figure 15 : Évolution du taux annuel de participation au programme national de dépistage organisé du cancer du sein, tous âges et par âge, France entière, de 2005 à 2024

Conclusion



Résultats

- Lien médias / intérêt public variable selon la campagne
- L'attention publique ne dépend pas uniquement de l'exposition médiatique



Conclusion

Prochaines étapes

- Affiner l'intégration de Medic'AM
- Modèle de Granger non linéaire
- Étudier le lien GT → Medic'AM
- Cibler des campagnes à saisonnalité plus marquée pour Medic'AM : Mois sans Tabac, Journées mondiales

ANNEXES

Annexe 1 : Google Trends et MediaCloud

Google Trends (GT)

- **Indice d'intérêt relatif** (0-100) lié aux requêtes Google dans une zone donnée
- Indice **100** → **maximum local** sur la période définie
- Utilisation de **PyTrends**
- Plage < 9 mois → données quotidiennes
- Plage 9 mois - 5 ans → données hebdomadaires
- Plage > 5 ans → données mensuelles

MediaCloud (MC)

- Volume des **articles médiatiques**
- Collection de **journaux français**
- Accès via API mediacloud → **requêtes par mots-clés / thématiques**
- Démarche d'**extraction** des URL des articles puis du texte (module newspaper3k)
- Construction d'**indicateurs d'exposition médiatique** (normalisation 0-100)

Annexe 2 : Construction des requêtes

- Enjeu : définir des **requêtes optimales**
 - Mauvaise requête → bruit dans le signal, biais d'interprétation
- Stratégie GT : **enrichissement itératif** des termes
 - **Snowball sampling** (expansion progressive des termes) sur différents **rounds** pour **GT**, puis **filtration** manuelle
- Stratégie MC :
 - **Extraction** URL, texte
 - Sélection des **k-uplets** les plus **fréquents** dans les articles, avec **filtration** manuelle

Annexe 3 : Mots-clés utilisés

Google Trends

- **Octobre Rose** : octobre rose + cancer du sein + dépistage sein + mammographie + ruban rose
- **Dry January** : dry january + janvier sans alcool + mois sans alcool + sevrage alcool
- **Movember** : movember + cancer de la prostate + dépistage prostate + moustache novembre
- **Mars Bleu** : mars bleu + cancer du côlon + dépistage côlon + coloscopie + cancer colorectal

MediaCloud

- **Octobre Rose** : octobre rose OR cancer sein OR lutte contre cancer sein OR dépistage cancer sein OR mois octobre rose
- **Dry January** : dry january OR consommation alcool OR mois alcool OR boire alcool mois OR dry january janvier OR alcool mois janvier
- **Movember** : movember OR cancer prostate OR mois movember OR masculin cancer prostate OR maladie masculin cancer prostate
- **Mars Bleu** : mars bleu OR cancer colorectal OR dépistage cancer colorectal OR cancer colorectal cancer OR mois mars bleu

Annexe 4 : Snowball sampling GT

- Mars Bleu : résultats pour différentes **itérations**
 - **Convergence** du signal vers une forme stable si $r \rightarrow +\infty$




Figure 15 : Convergence du signal de Mars Bleu GT

Annexe 5 : Top k-uplets MC

- Mots **les plus fréquents** dans les articles
 - Base de sélection pour la requête MediaCloud




Figure 16 : Exemple de répartition de demandes sur Google Trends pour la campagne Dry January en 2022

Annexe 6 : Choix des lags (p,q) par minimisation AIC




Figure 17: Heatmap choix des lags par critère AIC pour toutes les campagnes (MC->GT et GT->MC)

Annexe 7 : Calcul de la p-value

Statistique de Fisher

$$F = \frac{(RSS_{\text{red}} - RSS_{\text{full}})/q}{RSS_{\text{full}}/(n - p - q - 1)} \sim F(q, n - p - q - 1)$$

n = nombre d'observations, p = lags de la variable dépendante, q = lags de la variable explicative

$$p\text{-value} = P(F(q, n - p - q - 1) \geq F_{\text{obs}})$$

- $p\text{-value} < 0,005$: on rejette (H_0) à 5%
- Dry January : 0.000896 (GT->MC), 0.00015 (MC->GT)
- Mars Bleu : $2.7e-5$ (GT->MC), 0.026 (MC->GT)
- Movember : 0.0001 (GT->MC), 0.002 (MC->GT)
- Octobre Rose : 0.0003 (GT->MC), 0.0007 (MC->GT)

Annexe 8 : décompositions séries Medic'AM



Figure 18 : Décomposition STL Medic'AM, MC, GT pour Octobre Rose

Annexe 9 : Explication de STL

- Création de sous série saisonnières : (Jan2015,Jan2016,Jan2017,...)(Feb2015,Feb2016,...)

- Régression Locale LOESS sur chaque sous série

$$\min_{\beta} \sum_i w_i (y_i - \beta_0 - \beta_1 x_i)^2$$

$$\text{avec } w_i = \left(1 - \left|\frac{x_i - x_0}{d}\right|^3\right)^3$$

- Désaisonnalisation de la série : $D_t = y_t - S_t$
- Puis on estime de nouveau la saisonnalité sur $y_t - D_t$
- On itère jusqu'à stabilisation.

Annexe 10 : décompositions séries GT&MC




Figure 19 : Décomposition STL pour toutes les campagnes (Google Trends)

Annexe 10 : coefficients α_k et β_k




Figure 20 : Coefficients autorégressifs en fonction du lag

Annexe 11 : codes ATC Medic'AM

Dry January

Code ATC	Molécule	Noms commerciaux	Notes
N07BB03	Acamprosa te	Aotal, Campral, génériques	Réduction du craving
N07BB05	Nalméfène	Selincro	Réduction de consommation
N07BB04	Naltrexone	Revia, génériques	Abstinence
N07BB01	Disulfirame	Espéral	Aversion à l'alcool

Mars Bleu

Code ATC	Molécule	Noms commerciaux	Notes
L01BC06	Capécitabine	Xeloda, génériques	Chimiothérapie orale, cancer colorectal (et sein)
L01EX05	Régorafénib	Stivarga	Cancer colorectal métastatique

Octobre Rose

Code ATC	Molécule	Noms commerciaux	Indication principale
L02BA01	Tamoxifène	Nolvadex	Cancer du sein RH+ (pré-ménopause)
L02BG03	Anastrozole	génériques	Cancer du sein RH+ (post-ménopause)
L02BG04	Létrozole	Femara, génériques	Cancer du sein RH+ (post-ménopause)
L02BG06	Exémestane	Aromasine, génériques	Cancer du sein RH+ (post-ménopause)
L02BA03	Fulvestrant	Faslodex	Cancer du sein RH+ avancé

Movember

Code ATC	Molécule	Noms commerciaux	Indication
L02AE02	Leuproréline	Leptoprol, Eligard	Cancer prostate (analogue LHRH)
L02AE03	Goséréline	Zoladex	Cancer prostate (analogue LHRH)
L02AE04	Triptoréline	Decapeptyl	Cancer prostate (analogue LHRH)
L02BB03	Bicalutamid e	génériques	Antiandrogène
L02BB04	Enzalutamid e	Xtandi	Antiandrogène de nouvelle génération
L02BX03	Abiratérone	Zytiga	Cancer prostate résistant castration

Annexe 12 : Part de variance expliquée par saisonnalité/trend

campaign	source	pct_trend	pct_seasonal	pct_resid	cov_share
Dry January	Medicam (ventes)	67.686	17.373	14.941	-0.006
Dry January	MediaCloud (presse)	5.034	88.942	6.024	0.086
Dry January	Google Trends (recherches)	2.207	82.510	15.284	-0.238
Octobre Rose	Medicam (ventes)	91.308	4.499	4.193	-0.004
Octobre Rose	MediaCloud (presse)	6.689	80.640	12.671	0.148
Octobre Rose	Google Trends (recherches)	18.589	80.195	1.215	-0.016
Mars Bleu	Medicam (ventes)	80.274	7.430	12.296	-0.023
Mars Bleu	MediaCloud (presse)	30.979	39.244	29.776	-0.180
Mars Bleu	Google Trends (recherches)	48.419	36.901	14.680	-0.086
Movember	Medicam (ventes)	96.037	2.337	1.626	0.003
Movember	MediaCloud (presse)	1.144	71.304	27.553	0.182
Movember	Google Trends (recherches)	11.507	82.898	5.595	-0.080

Annexe 12 : Part de variance expliquée par saisonnalité/trend

=====					
campaign	pct_trend	pct_seasonal	pct_resid	cov_share	
Dry January	67.686	17.373	14.941	-0.006	
Octobre Rose	91.308	4.499	4.193	-0.004	
Mars Bleu	80.274	7.430	12.296	-0.023	
Movember	96.037	2.337	1.626	0.003	
Mois sans tabac	97.362	1.467	1.172	0.023	
Santé mentale	50.349	28.876	20.775	0.061	

Annexe 12 : Part de variance expliquée par saisonnalité/trend après 2020

campaign	pct_trend	pct_seasonal	pct_resid	cov_share
Dry January	73.781	15.146	11.073	0.079
Octobre Rose	75.035	13.419	11.545	-0.027
Mars Bleu	25.437	25.716	48.847	-0.444
Movember	91.838	4.910	3.252	0.069
Mois sans tabac	80.852	13.458	5.690	0.002
Santé mentale	37.393	39.675	22.931	0.097

Annexe 12 : Part de variance expliquée par saisonnalité/trend




Figure 21 : Décomposition STL Mois sans tabac et Santé mentale

Annexe 13 : Evolution de l'incidence des cancers en France métropolitaine




Figure 22 : Évolution de l'incidence des cancers de France métropolitaine